

签名森林热启动与修复增强的离散模拟分岔算法

用于基因定相 Max-Cut 求解

李天一

摘要

基因定相在本赛题中被转化为带权最大割/伊辛图优化问题。针对公开图规模大、强耦合边信息明显且运行时间受限的特点，本文设计签名森林热启动与修复增强的离散模拟分岔算法（SF-DSB-R）。该算法先从高权重边构造签名森林，并通过边符号传播得到结构化初始自旋；随后以离散模拟分岔进行精炼；当公开样例基线尚未达到时，再以单点翻转和子树块翻转修复残余冲突，并以修复态重启离散模拟分岔。该流程不构造稠密矩阵，主要依赖稀疏矩阵乘法、边表筛选和森林路径操作。公开Graph_data 全12图本地实验显示，最终提交的main.py在官方judger.py下得分约99.86，总求解时间约0.73秒；同环境下官方样例Baseline-SB总时间约965.47秒。消融实验显示，去除签名森林初值后平均AccRatio从1.000000降至0.906453，说明结构化热启动是公开样例质量提升的主要来源。本文结果仅对应赛题公开最大割图实例和本地环境，不代表官方隐藏评测，也不直接声称在QHap的真实测序基因定相基准数据集上取得更优结果。

关键词：量子启发式算法；基因定相；最大割；伊辛模型；离散模拟分岔；签名森林

1 问题背景与描述

基因定相旨在根据测序读段推断同源染色体上的等位基因共遗传关系。HapCUT、WhatsHap 和 HapCUT2 分别从图划分、带权最小错误校正和多测序平台鲁棒性等角度推动了该问题的算法发展[2-4]。QHap v2 进一步将基因定相中的核心优化形式表述为最大割，并使用 GPU 加速的模拟分岔求解，显示了量子启发式优化在计算基因组学中的潜力[1]。

本赛题不要求从原始测序读段重新构建定相图，而是直接给出最大割/伊辛图实例。每个节点对应一个二值自旋，边权描述两个节点取相同或相反符号时对目标函数的贡献。最终提交程序需要输出由-1和1组成的划分，使割值尽可能接近或超过公开基线，同时减少求解时间。因此，本文关注的是赛题给定图实例上的量子启发式组合优化，而不是完整生物学定相流程。

2 问题分析

2.1 最大割/伊辛建模

令 s_i 表示第 i 个节点的二值自旋或划分标签，其取值如式(1)。

`main.py`中的`read_graph_file(..., negate=True)`会先按赛题约定将边权取负，并得到CSR稀疏矩阵 G 。最终割值按式(2)计算，该式与`_calculate_cut_value`完全一致，也与官方`judge.py`的验证逻辑一致。

$$s_i \in \{-1, 1\}, \quad i = 1, \dots, n \quad (1)$$

$$C(s) = \frac{1}{4} (s^T G s - \sum_{i,j} G_{ij}) \quad (2)$$

由于公开图包含数千至上万节点和大量带权边，求解器必须避免 $O(N^2)$ 稠密存储，并将主要计算限制在稀疏矩阵乘法和边表操作中。后文的强边筛选、森林传播和局部修复均围绕该CSR矩阵 G 展开。

2.2 结构热启动的动机

SB、DSB、SimCIM、NMFA 和 LQA 都可被视为在伊辛能量地形中演化连续变量或平均场变量的量子启发式方法[5-9]。若从随机初值出发，算法需要先校正搜索方向，再靠迭代逼近高质量划分。公开图中的高权重边已经携带较强符号约束，因此可以先构造可靠的局部符号骨架，再将该骨架作为DSB初态，从而减少无效搜索。

3 方案描述

3.1 算法总览

SF-DSB-R的入口是最终提交文件`main.py`中的`maxcut_solver`。算法先读取稀疏图并提取唯一边表，再筛选高权重边构造签名森林；森林传播得到初始自旋后，算法调用DSB进行第一轮精炼；若公开基线尚未达到，则执行单点翻转、子树修复和最终DSB重启。局部修复不替代量子启发式主干，而是为最终DSB提供更稳定的重启状态。




图 1 SF-DSB-R 算法框架。该图展示本文方法在赛题 Max-Cut/Ising 图实例上的流程：从公开图构造稀疏边表，筛选高权重边形成签名森林并生成热启动；经 DSB 精炼后根据是否达到公开基线选择直接输出或触发局部修复与最终 DSB 重启，最终输出自旋划分并计算 AccRatio、运行时间和最终得分。修复模块为未达到公开基线时的条件触发分支，并非每次求解都无条件执行。图中模块均对应 main.py 中真实实现。

3.2 签名森林热启动

签名森林初始化函数 (`_signed_tree_initialization`) 先提取无向唯一边表 E ，并按式(3)保留绝对权重最大的 K 条候选边。其中 α 由图密度自适应选择：当 $|E|/n$ 大于 250 时取 44，否则取 7；这对应源码中的 `factor=44` 或 `factor=7`。随后，代码在候选边上以 $-|G_{ij}|$ 为代价调用 `minimum_spanning_tree`，概念上等价于式(4)的高可靠签名森林构造。

$$K = \min(|E|, \max(n - 1, \alpha n)), E_K = \text{Top}K_{(i,j) \in E} |G_{ij}| \quad (3)$$

$$T = \operatorname{argmax}_{F \subseteq E_K} \sum_{(i,j) \in F} |G_{ij}|, F \text{ 为森林} \quad (4)$$

得到森林 T 后，算法沿森林边传播符号关系生成结构化初始自旋，如式(5)所示。源码中若 G_{ij} 大于等于 0 则传播相同符号，否则传播相反符号；若森林不连通，再由分量对齐步骤确定不同连通分量之间的相对方向。

$$s_j^{(0)} = \text{sign}(G_{ij}) s_i^{(0)}, (i, j) \in T \tag{5}$$

3.3 分量对齐、DSB 精炼与修复

若签名森林不连通，森林分量对齐函数（_align_forest_components）将连通分量压缩为超节点，并聚合跨分量边权以求解粗粒度符号关系。

随后，DSB精炼函数（_qaia_refine）调用qaia.DSB，并以结构化自旋初始化状态。本文不补充未核实的DSB演化公式，因为最终提交代码直接依赖qaia.DSB的实现。若第一轮DSB未达公开基线，单点翻转下降（_single_spin_descent）按式(6)维护局部场并执行贪心翻转；子树块修复（_subtree_refinement）再利用森林路径差分执行块级翻转。修复模块是困难实例保险机制，公开样例的主要质量来源仍是签名森林初值。

$$h_i = (G s)_i, \Delta_i = -s_i h_i; \text{ 若 } \Delta_i > 0, \text{ 则翻转 } s_i \tag{6}$$

4 结果与分析

4.1 实验设置

Baseline-SB为baseline_main.py；SF-DSB-R为main.py中的改进算法。公开Graph_data全12图在本地运行，环境为macOS 15.6.1、Apple M4 Pro、Python 3.13.0、numpy 2.2.6、scipy 1.15.2和torch 2.7.0。DSB、BSB、SimCIM、NMFA和LQA采用统一轻量配置，仅作同环境参考。

表1 全量公开 Graph_data 本地总体对比

方法	完成图数	平均 AccRatio	最低 AccRatio	总时间/秒	Score
Baseline-SB	12	0.999592	0.997532	965.47	39.00
DSB	12	0.953637	0.929937	6.19	0.00
BSB	12	0.992441	0.984769	6.24	5.46
SimCIM	12	0.912591	0.898601	10.14	0.00
NMFA	12	0.975330	0.961952	10.23	0.00
LQA	12	0.969294	0.962361	6.84	0.00
SF-DSB-R	12	1.000000	1.000000	0.73	99.86

表1显示，SF-DSB-R在公开12图上保持平均AccRatio约1.000000，总时间约0.73秒；Baseline-SB 也能获得较高平均AccRatio，但总时间约965.47秒，最终分数明显较低。统一轻量配置下，BSB是QAIA变体中质量最高的参考方法，但平均AccRatio仍低于SF-DSB-R。




图2 Baseline-SB 与 SF-DSB-R 的公开样例汇总对比。三联图分别显示平均 AccRatio、总运行时间和最终得分；运行时间轴使用对数尺度。数据为本文在公开 Graph_data 全 12 图上的本地实验汇总。




图3 QAIA变体质量-时间权衡及代表性收敛过程。a为全量12图散点图；b-e为block6、block18、block23、block31单次运行轨迹。曲线仅说明代表图过程，不作统计显著性结论。

4.2 消融实验

表2 消融实验汇总

版本	平均 AccRatio	最低 AccRatio	总时间/秒	解释
SF-DSB-R	1.000000	1.000000	0.72	完整流程
w/o warm start	0.906453	0.867278	0.69	移除结构初值后质量显著下降
w/o single-spin	1.000000	1.000000	0.72	公开样例中被早停掩盖，质量基本不变
w/o subtree repair	1.000000	1.000000	0.72	公开样例中被早停掩盖，质量基本不变
w/o final DSB	1.000000	1.000000	0.70	公开样例中修复态已达到 baseline

消融结果表明，签名森林热启动是当前公开图上最关键的质量来源。移除热启动后平均AccRatio降至0.906453，最低AccRatio为0.867278。相比之下，移除单点翻转、子树修复或最终DSB在公开样例上几乎不改变最终割值，这不说明这些模块没有价值，而是说明公开样例基线常在早期阶段已经达到，后续修复更多体现为稳定性保险。




图4 消融实验。左图显示热启动对平均AccRatio的贡献最大；右图显示各模块对公开12图总时间的影响较小。数据为本文在公开 Graph_data 全 12 图上的消融实验汇总。

4.3 QHap 对比边界

当前材料尚不具备与QHap进行完整基因定相任务公平对比的条件。公平比较需要相同或同源测序数据和评价协议。指标还应覆盖switch error、hamming error、单倍型N50、定相完整度（phasing completeness）、SNP完整度（SNP completeness）和运行时间。本文尚未复现QHap在真实测序数据上的上述指标，因此不直接声称在生物学定相任务上超过QHap。本文证据支持的结论是：在赛题给定的公开最大割/伊辛图实例上，本文方法相比Baseline-SB和若干QAIA变体取得更好的质量-时间表现。若未来把本文方法作为QHap中最大割求解模块的替代候选，还需要在QHap原始或同源数据集上完成端到端复

现实验。

5 创新点总结

本文的主要创新点包括五个方面。第一，将强边符号关系组织成签名森林，把图结构先验转化为DSB热启动。第二，根据图密度调节强边保留规模，使稠密图保留更多关键约束。第三，用分量压缩与符号对齐解决森林不连通时的全局方向不确定。第四，采用DSB-局部修复-DSB的两阶段流程，保持量子启发式主线，同时为困难实例保留局部纠错能力。第五，使用稀疏矩阵、边表筛选和森林路径操作控制运行开销。

6 参考文献

- [1] Zhang R, Tao X-Z, Chen Y, et al. QHap: Quantum-Inspired Haplotype Phasing[EB/OL]. arXiv:2603.25762v2, 2026.
- [2] Bansal V, Bafna V. HapCUT: an efficient and accurate algorithm for the haplotype assembly problem[J]. Bioinformatics, 2008, 24(16): i153-i159.
- [3] Patterson M, Marschall T, Pisanti N, et al. WhatsHap: weighted haplotype assembly for future-generation sequencing reads[C]//German Conference on Bioinformatics 2014. OASICs, 2014, 37: 237-249.
- [4] Edge P, Bafna V, Bansal V. HapCUT2: robust and accurate haplotype assembly for diverse sequencing technologies[J]. Genome Research, 2017, 27(5): 801-812.
- [5] Okuyama T, Sonobe T, Kawarabayashi K, Yamaoka M. Combinatorial optimization by simulating adiabatic bifurcations in nonlinear Hamiltonian systems[J]. Science Advances, 2019, 5(4): eaav2372.
- [6] Goto H, Tatsumura K, Dixon A R. High-performance combinatorial optimization based on classical mechanics[J]. Science Advances, 2021, 7(6): eabe7953.
- [7] Tiunov E S, Ulanov A E, Lvovsky A I. Annealing by simulating the coherent Ising machine[J]. Optics Express, 2019, 27(7): 10288-10295.
- [8] King A D, Bernoudy W, King J, et al. Emulating the coherent Ising machine with a mean-field algorithm[EB/OL]. arXiv:1806.08422, 2018.
- [9] Bowles J, Dauphin A, Huembeli P, et al. Quadratic unconstrained binary optimization via quantum-inspired annealing[J]. Physical Review Applied, 2022, 18: 034016.
- [10] Stern M, Patel N, Gonon L, et al. Performance of quantum annealing inspired algorithms for

combinatorial optimization problems[J]. Communications Physics, 2024.

[11] Dellal A, Goto H, Oshiyama H, et al. Tabu-Enhanced Simulated Bifurcation for combinatorial optimization[J]. Communications Physics, 2026.

[12] Xu H, Liu J, Wang W, et al. MindSpore Quantum[EB/OL]. arXiv:2406.17248, 2024.

附录A 算法实现与补充材料

本附录补充正文未展开的代码对应关系、关键参数、复现实验说明和比较边界。所有条目均以最终提交文件main.py、README_运行说明.md 和本地公开样例实验记录为依据；未运行或无法公平比较的内容不写成结果。

A.1 main.py 代码结构与论文模块对应

SF-DSB-R的实现入口为maxcut_solver。 签名森林和分量对齐负责生成结构化热启动，_qaia_refine调用qaia.DSB承担主要求解与最终精炼；单点翻转和子树块修复只在主DSB未达到公开基线时触发，用于构造更稳定的restart状态。

表A1 论文模块与 main.py 函数对应关系

模块	论文描述	main.py对应函数	实现	说明
图读取	读取Graph_data并构造稀疏图	read_graph_file	是	返回CSR矩阵G、公开baseline和baseline time
割值计算	按赛题目标计算C(s)	_calculate_cut_value	是	使用G @ s和G.data.sum，避免稠密矩阵
签名森林	筛选高权边并传播符号	_signed_tree_initialization	是	用于热启动，不是最终主求解器
分量对齐	对不连通森林分量定向	_align_forest_components	是	构造压缩分量图并调用小图精炼
DSB精炼	量子启发式主干搜索	_qaia_refine	是	调用qaia.DSB，提交解来自DSB符号
局部修复	单点翻转与子树块翻转	_single_spin_descent; _subtree_refinement	条件触发	仅当主DSB未达公开基线时辅助restart
最终输出	返回int8自旋划分	maxcut_solver	是	输出{-1,1}^N，供judge.py评分

因此，本文不将SF-DSB-R表述为纯经典MST、贪心或局部搜索算法。经典图结构步骤用于热启动和重启辅助，核心搜索路径仍保留在DSB/QAIA量子启发式精炼中。

A.2 关键公式与实现对应

表A2 公式、符号与代码实现对应

对象	论文公式或符号	代码位置	实现说明
自旋变量	$s_i \in \{-1, 1\}$	maxcut_solver返回值	最终返回np.int8类型的+1/-1划分
图矩阵	G	read_graph_file(..., negate=True)	按赛题约定取负后构造CSR稀疏矩阵
割值	$C(s)=1/4(s^T G s - \sum G_{ij})$	_calculate_cut_value	与正文式(2)一致，并与judger.py验证逻辑一致
强边筛选	$\text{rank } G_{ij} ; K=\min(E , \max(n-1, \alpha n))$	_signed_tree_initialization	edge_density>250取factor=44, 否则取factor=7
签名森林	在 E_K 上最大化强边绝对权重	minimum_spanning_tree	以 $- G_{ij} $ 为代价构造高权签名森林
热启动传播	$s_j^{(0)} = \text{sign}(G_{ij}) s_i^{(0)}$	_signed_tree_initialization	$G_{ij} \geq 0$ 传播相同符号，否则传播相反符号
单点修复	$h_i = (G s)_i; \Delta_i = -s_i h_i$	_single_spin_descent	若增益为正则翻转，并用CSR邻接表增量更新局部场
DSB过程	不补写未核实动力学方程	_qaia_refine	正文只说明调用qaia.DSB，避免引入与源码不一致的方程

A.3 参数设置与工程实现

表A3 关键参数与工程设置

位置	参数	取值	作用
强边候选	factor	44或7	按edge_count/n是否大于250自适应选择候选边规模
主DSB	n_iter, batch_size, dt, xi	16, 1, 1.0, 8e-3	从签名森林热启动执行第一轮DSB精炼
分量小图DSB	n_iter, batch_size, dt, xi	16, 1, 1.0, 3e-3	辅助森林分量符号对齐
最终DSB	n_iter, batch_size, dt, xi	6, 1, 1.0, 3e-4	从修复态重启，输出最终DSB符号
DSB初值	x	0.15 * initial_spins	batch_size=1时将结构自旋写入连续变量初态
单点翻转	max_passes	8	基于局部场执行有限轮贪心修复
子树修复	factor; max_rounds	24; 1或max(1,max_iterations)	先用强边快速修复，必要时再用全边修复
早停判断	round(cut,5)>=round(baseline,5)	_baseline_reached	公开baseline达到后直接返回，减少不必要修复

实现上，图结构始终以CSR矩阵和无向唯一边表为主，局部场、强边筛选和树路径差分均避免 $O(N^2)$ 稠密存储。__main__中的评分复核使用ALPHA=1000.0和BETA=1.0，但正式提交仍以官方judger.py为准。

A.4 实验复现说明

表A4 复现命令与输出说明		
目标	命令或文件	说明
安装依赖	python3 -m pip install numpy scipy torch	torch主要用于官方judger.py验证
直接运行	python3 main.py	读取同目录Graph_data并打印逐图cut、AccRatio和时间
判题器验证	python3 judger.py	计算Weighted Acc Score、Total Solve Time和Final Score
输入数据	Graph_data/*.txt	首行含节点数、边数、baseline cut和baseline time
输出形式	int8 +/-1 partition	maxcut_solver返回长度为N的自旋划分
论文实验脚本	final_v4/experiments/run_experiments.py	生成公开样例对比、QAIA变体和消融TSV
图表脚本	final_v4/figures/make_figures_v4.py	生成论文图表，正式zip不包含该目录

论文中的数值来自本地公开Graph_data全12图验证和judger.py公开样例输出。该结果用于说明当前机器和公开样例上的质量—时间表现，不等同于官方隐藏测试成绩；不同硬件和依赖版本可能导致运行时间小幅波动。

A.5 消融实验和对比边界

表A5 已完成实验与可支持结论			
实验	范围	可支持结论	边界
总体对比	Baseline-SB与SF-DSB-R，公开12图	SF-DSB-R在本地公开图上质量-时间表现更好	不代表隐藏测试成绩
QAIA变体	DSB、BSB、SimCIM、NMFA、LQA	统一轻量配置下SF-DSB-R表现更优	不代表各算法最优调参上限
消融实验	移除热启动、单点翻转、子树修复、final DSB	热启动是公开样例主要贡献来源	修复模块在公开样例中多被早停掩盖
收敛轨迹	4个代表图的单次运行记录	用于展示质量-时间趋势	不作统计显著性结论
QHap端到端	未运行	待补充	不得据此声称完整定相任务超过QHap

公开Max-Cut/Ising图上，SF-DSB-R较Baseline-SB和若干QAIA变体有更好的质量—时间表现，主要贡献来自签名森林热启动。

A.6 与QHap等完整基因定相方法的公平对比条件

表A6 QHap公平对比所需条件		
条件	当前状态	后续需要
QHap代码或流程	未形成可复现实验闭环	获取代码、版本和完整运行命令
同源测序数据	当前仅有赛题Graph_data图实例	使用相同或可说明差异的数据集
标准答案	Graph_data只支持割值验证	准备ground truth或标准评价文件
端到端指标	未计算switch error等指标	补充switch error、hamming error、haplotype N50、定相完整度、SNP完整度和运行时间
硬件环境	当前为本地公开样例环境	记录相同或可解释差异的CPU/GPU和依赖版本
模块嵌入	SF-DSB-R当前是Max-Cut求解器	明确嵌入QHap的Max-Cut/Ising求解环节，而非替代完整pipeline

因此，当前论文不把Graph_data结果等同于完整生物学定相pipeline结果。若后续证明本文方法在QHap相关流程中具有优势，应在同源数据、 相同评价指标和可复现环境下重新完成端到端实验。