

# 面向 Pareto 覆盖的量子多目标组合优化

罗马花椰菜<sup>1</sup>

## 摘要

本文研究固定量子采样预算下的五目标 Ising 多目标优化及大规模样本后处理加速。赛题要求 `main1` 严格返回由量子线路产生的 100000 条样本，经典部分只能评价、筛选和组织量子样本，不能额外生成候选解；因此算法设计的重点在于把有限 shots 同时分配给低能开发、权重方向覆盖和 Pareto 前沿多样性维护。围绕这一约束，本文设计了强单轮混合深度（mixed-depth）QAOA、简单多轮热启动拓展和四轮 Pareto 协同反馈三类量子采样路线，并配套实现 `main2` 的向量化非支配筛选与超体积后处理。本地实验中，强单轮方案通过结构化权重锚点、最远点补集和  $P = 6/4/3$  混合深度分配取得 `score_k5=230.016421`；四轮协同方案在固定 100000 shots 内引入跨权重非支配前沿反馈，取得 `score_k5=229.920256`。云端提交记录中，强单轮系列总分达到 210+ 分，多轮 hybrid 系列总分达到 211+ 分。轮数与采样次数分配扫描显示，原始方案从一轮到四轮逐步提升，五、六轮因单轮样本变薄出现回落；`main2` 在 `large10` 固定配置下保持输出一致，并相对评分基准实现平均约 71.4% 的速度提升。

## 目录

|                                      |   |
|--------------------------------------|---|
| 一、问题背景 .....                         | 2 |
| 1.1 量子计算与组合优化 .....                  | 2 |
| 1.2 多目标 Ising 优化 .....               | 2 |
| 1.3 评分目标与合法边界 .....                  | 3 |
| 二、赛题分析 .....                         | 3 |
| 2.1 从多目标问题到量子采样方向 .....              | 3 |
| 2.2 收敛与覆盖的矛盾 .....                   | 4 |
| 2.3 三类实验路线 .....                     | 4 |
| 三、解决方案 .....                         | 4 |
| 3.1 强单轮混合深度 QAOA .....               | 4 |
| 3.2 简单多轮拓展对照 .....                   | 5 |
| 3.3 四轮 Pareto 协同反馈 .....             | 6 |
| 3.4 <code>main2</code> 等价后处理加速 ..... | 6 |

---

<sup>1</sup>f.g.m.leonardo@gmail.com, y3lin@spinq.cn, chenronghang2020@outlook.com

|                              |    |
|------------------------------|----|
| 四、实验结果与分析 .....              | 8  |
| 4.1 实验设置 .....               | 8  |
| 4.2 三类 main1 路线对比 .....      | 8  |
| 4.3 协同轮次与采样次数分配消融 .....      | 8  |
| 4.4 与 public10 精确上界的距离 ..... | 9  |
| 4.5 main2 large10 结果 .....   | 10 |
| 4.6 本地结果与证据边界 .....          | 11 |
| 五、总结与展望 .....                | 11 |
| 参考文献 .....                   | 11 |

## 一、问题背景

### 1.1 量子计算与组合优化

量子计算利用量子叠加、干涉和纠缠等物理特性，在搜索、优化和量子系统模拟中具有不同于经典计算的表达能力。对于组合优化问题，候选解空间通常随变量数指数增长，经典算法很容易在精确性、运行时间和内存消耗之间遇到瓶颈。量子近似优化算法（Quantum Approximate Optimization Algorithm, QAOA）将组合优化目标写入问题 Hamiltonian，再通过参数化量子线路产生候选解分布，为在中等规模量子设备上探索高质量解提供了可行框架 [1, 2]。

组合优化本身也具有重要应用价值。网络设计、资源调度、投资组合、芯片布局和机器学习模型选择都可以抽象为离散变量上的目标函数优化；当多个目标同时存在且互相冲突时，问题会从寻找单个最优解转化为寻找一组互不支配的折中解。赛题以多目标 Ising 模型作为统一表达，一方面保留了组合优化的离散难度，另一方面又要求算法在固定采样预算下同时兼顾量子线路质量、前沿覆盖和运行效率，因此适合检验量子采样与经典后处理协同优化的能力。

### 1.2 多目标 Ising 优化

现实决策通常需要同时权衡多个冲突目标。若一个解在所有目标上不劣于另一个解，并至少在一个目标上更优，则称前者支配后者；决策空间中的非支配解构成 Pareto 解集，其目标向量构成 Pareto 前沿。与寻找单个最优解不同，多目标优化要求前沿同时具有收敛性和分布广度。

赛题给定共享自旋变量的  $k = 5$  目标 Ising 模型。对网格图  $G = (V, E)$  和自旋

$z_i \in \{-1, +1\}$ , 第  $t$  个目标为

$$f^{(t)}(z) = \sum_i h_i^{(t)} z_i + \sum_{(i,j) \in E} J_{ij}^{(t)} z_i z_j, \quad t = 1, \dots, 5. \quad (1)$$

五个目标共享同一个  $z$ , 但局部场和耦合系数不同, 因此不同目标偏好的低能解可能存在冲突。公开小规模实例为  $4 \times 5$  网格, 共 20 个量子比特。评价时先以各目标的精确上下界归一化, 再以参考点  $r = (1.01, \dots, 1.01)$  计算超体积 (hypervolume, HV)。HV 越大, 表示前沿越靠近理想区域且覆盖越充分 [3, 4]。量子近似多目标优化的近期研究也表明, 标量化权重、量子线路采样与 Pareto 前沿选择可以形成自然结合 [5]。

### 1.3 评分目标与合法边界

**main1** 的总采样预算固定为  $B = 100000$ 。最终返回的每条自旋串都必须来自 Mind-Spore Quantum 量子线路。经典计算可以评价量子样本、去重、筛选非支配点和选择下一轮线路参数, 但不能通过穷举、整数规划、分支定界或局部搜索生成新的自旋串。其得分由相对基线的平均 HV 增益决定:

$$S_5 = 100000 \cdot \frac{1}{|D_5|} \sum_{d \in D_5} \max(HV_d - HV_d^{\text{base}}, 0). \quad (2)$$

**main2** 要求在输出语义不变的前提下加速大规模随机样本后处理, 其原始加分写为

$$S_{\text{large}}^{\text{raw}} = \frac{1}{|D_L|} \sum_{d \in D_L} \max\left(\frac{T_d^{\text{base}} - T_d^{\text{submit}}}{T_d^{\text{base}} + \epsilon}, 0\right). \quad (3)$$

总分为

$$S = S_5 + 10 \cdot S_{\text{large}}^{\text{raw}}. \quad (4)$$

因此, **score\_k5** 衡量小规模量子采样质量, 总分还受到 **main2** 运行环境和加速效果影响; 二者必须分别报告。

## 二、赛题分析

### 2.1 从多目标问题到量子采样方向

对五维非负归一化权重向量  $\lambda = (\lambda_1, \dots, \lambda_5) \in \mathbb{R}_{\geq 0}^5$ , 满足  $\sum_{t=1}^5 \lambda_t = 1$ , 将五个目标投影为

$$H_\lambda(z) = \sum_{t=1}^5 \lambda_t f^{(t)}(z). \quad (5)$$

每个  $\lambda$  定义目标空间中的一个权衡方向, QAOA 通过交替施加问题 Hamiltonian 与 mixer Hamiltonian 产生候选自旋串 [1, 2]。本文采用一组分散的  $\lambda$ , 同时采样极端目标方向和折中方向。

设共有  $M$  个方向，第  $m$  个方向分配  $b_m$  个量子测量采样次数，则

$$\sum_{m=1}^M b_m = B. \quad (6)$$

增大  $b_m$  有利于在该方向上发现低能样本，但会挤占其它方向的预算；增加轮数又会把每轮样本变薄。固定预算的本质不是把线路运行更多次，而是在方向覆盖、单方向采样强度与反馈精炼之间分配有限资源。

## 2.2 收敛与覆盖的矛盾

较深 QAOA 线路具有更高的线路复杂度和表达能力，但也会增加运行时间；较浅线路运行成本较低。热启动可使后续线路偏向已有样本附近 [6]。本文将线路深度、热启动和采样次数作为联合配置进行实验比较，不单独假设某一项必然提高 HV。

据此，我们构造三条实验路线：强单轮使用多权重和混合深度；简单多轮在固定权重下加入标量反馈；四轮协同使用跨权重 Pareto 前沿选择种子。三条路线用于比较不同量子采样组织方式在固定预算下的结果。

## 2.3 三类实验路线

强单轮质量基线一次性覆盖 100 个权重方向，并使用  $P = 6/4/3$  的混合深度线路；简单多轮拓展保持强单轮的权重与深度规则，只把每个方向的采样次数拆成三轮，并按归一化标量分数选择热启动种子；四轮协同方案固定  $P = 4$ ，从本轮跨权重非支配前沿中选择种子，并联合调整活跃权重、热启动强度和采样次数分配。三条路线使用相同的 100000 shots 预算，用于比较单轮覆盖、固定标量反馈和 Pareto 前沿反馈的差异。

# 三、解决方案

## 3.1 强单轮混合深度 QAOA

`code/answer_singleround.py` 中的 100 个权重方向并非直接随机抽取，而是采用“结构化锚点 + 最远点补集”的方式确定。首先构造覆盖五维单纯形关键区域的确定性锚点：对每个目标设置若干近坐标轴方向，用于保护单目标极端区域，例如  $(0.995, 0.00125, 0.00125, 0.00125, 0.00125)$  代表几乎只偏向目标 1；对两目标组合设置折中方向，用于覆盖 Pareto 前沿的边界过渡，例如  $(0.495, 0.495, 0.0033, 0.0033, 0.0033)$  代表目标 1 与目标 2 的折中；对三目标组合设置内部折中方向，例如  $(0.33, 0.33, 0.33, 0.005, 0.005)$  代表前三个目标共同主导；同时加入均匀权重  $(0.2, \dots, 0.2)$  表示五目标均衡偏好。随后从固定的 1000 个候选权重池  $W$  中，按贪心最远点准则

$$\lambda_{\text{next}} = \arg \max_{\lambda \in W} \min_{\mu \in S} \|\lambda - \mu\|_2 \quad (7)$$

补齐剩余方向，其中  $S$  为当前已选权重集合。这样得到的 100 个  $\lambda$  同时覆盖单目标边界、两/三目标折中和中心区域，减少随机选权重可能造成的聚集和空洞；实际实现中还会依据少量实例配置分支对部分方向作确定性替换，但不改变覆盖优先的设计原则。

每个方向总计采样 1000 次，严格满足  $100 \times 1000 = 100000$ 。算法根据权重形状特征和少量实例统计信息配置混合深度，默认 50 个方向使用  $P = 6$ 、25 个使用  $P = 4$ 、25 个使用  $P = 3$ 。具体地，将权重分量按降序记为  $\lambda_{(1)} \geq \lambda_{(2)} \geq \dots$ ，并计算最大权重  $r_{\text{peak}} = \lambda_{(1)}$ 、前二权重和  $r_{\text{top2}} = \lambda_{(1)} + \lambda_{(2)}$ 、前二间隔  $g_{12} = \lambda_{(1)} - \lambda_{(2)}$  以及归一化熵

$$H(\lambda) = -\frac{\sum_i \lambda_i \log(\lambda_i + \epsilon)}{\log 5}. \quad (8)$$

在启用权重形状分层的配置中， $P = 6$  优先分配给  $r_{\text{peak}}$  较高、 $g_{12}$  较大且熵较低的边界方向，用于强化潜在极端 Pareto 区域的低能开发； $P = 4$  更多分配给前两个目标占比较高且相对均衡、熵处于中间水平的双目标过渡方向，用于平衡收敛与覆盖；其余较均衡或补充覆盖的方向使用  $P = 3$ ，以控制运行成本并保留采样分布宽度。实际实现还会依据实例统计特征切换少量预设 profile，例如调整  $P = 6/4/3$  的数量比例；这属于竞赛调优层，不改变“深度作为有限资源按前沿作用分配”的基本原则。部分深层方向进一步使用 800 次  $P = 6$  与 200 次  $P = 4$  的补充采样，以在低能开发之外增加局部多样性。

该方案没有跨轮热启动。经典部分仅决定权重和线路深度，最终样本全部来自 QAOA。它代表“充分覆盖、一次完成”的强质量基线，整体流程见算法 1。

---

#### Algorithm 1 强单轮混合深度量子采样

---

**Require:** 权重候选池  $W$ 、边界锚点，方向数  $M = 100$ ，总预算  $B = 100000$

- 1: 由结构化锚点初始化集合  $S$ ，再按最远点准则从  $W$  中补齐 100 个权重方向。
  - 2: **for** 每个权重方向  $\lambda_j$  **do**
  - 3:   根据权重特征和实例统计信息确定线路深度  $P \in \{3, 4, 6\}$ 。
  - 4:   构造对应 QAOA 线路；部分深层方向拆分为主深度和补充深度采样。
  - 5:   采样该方向的量子比特串，并写入全局样本集合。
  - 6: **end for**
  - 7: **return** 严格返回 100000 条量子线路生成的自旋串。
- 

混合深度的设计目的，是在较深线路的低能开发能力、较浅线路的采样分布宽度和总体运行成本之间取得平衡；因此它不是简单追求更大的线路深度，而是把深度预算投向对 Pareto 前沿覆盖更可能有贡献的方向。

### 3.2 简单多轮拓展对照

`code/answer_singleround_to_multi.py` 将每个权重方向的 1000 次采样拆为  $[600, 200, 200]$ 。每个非末轮结束后，对每个  $\lambda$  计算本轮量子样本的归一化标量分数，并

选择分数最低的自旋串作为下一轮热启动种子；热启动强度固定为 0.65。

在当前 public10 实验中，该简单三轮配置的 `score_k5` 低于强单轮，说明机械拆轮并加入固定标量反馈不能保证 HV 提升。由于没有独立组件消融，本文只将其作为完整对照方案报告。

### 3.3 四轮 Pareto 协同反馈

在强单轮方案之后，我们进一步实验多轮反馈；对应实现保存在 `code/answer_multiround.py`。论文主结果通过显式设置 `MOO_ROUND_SCHEDULE=4round_2` 获得，采用每轮 100 个活跃采样位置、固定线路深度  $P = 4$  和

$$[s_1, s_2, s_3, s_4] = [400, 400, 150, 50], \quad 100 \sum_{r=1}^4 s_r = 100000. \quad (9)$$

四轮协同方案中的 100 个活跃权重也来自同一个候选权重池，但其使用方式与强单轮不同。第一轮还没有历史样本，因此先用最远点采样从 1000 个候选方向中选出 100 个分散权重，以建立初始全局覆盖。这里的最远点采样不是对量子线路输出进行采样，而是在权重单纯形中的贪心选点过程：若  $S$  为当前已选权重集合，则每一步从候选池  $W$  中选择

$$\lambda_{\text{next}} = \arg \max_{\lambda \in W \setminus S} \min_{\mu \in S} \|\lambda - \mu\|_2, \quad (10)$$

即优先加入距离已有权重集合最近距离最大的候选方向。这样可以减少初始权重的聚集和空洞，使第一轮在无热启动信息时尽量覆盖不同目标偏好。每个非末轮结束后，算法不再重新随机选择 100 个方向，而是将本轮所有活跃权重产生的量子样本统一放回五目标空间，提取跨权重非支配前沿，并依据 HV 贡献、目标极 endpoint、目标空间距离和每个权重的种子数量上限筛选下一轮种子。被选中种子保留其来源权重，随后被重新映射到下一轮的 100 个活跃位置；因此，高价值前沿区域可以获得更多后续采样机会，同时距离约束和单权重上限避免少数权重方向垄断预算。热启动强度为

$$c_r = \min\{0.15 + 0.26(r - 1), 0.95\}, \quad (11)$$

并依据局部场幅值和节点度调整逐比特热启动强度。首轮没有热启动种子，因此该强度从第二轮开始实际生效。算法 2 列出其按轮执行步骤。

前两轮各保留 400 次采样，使初始采样和第一次反馈拥有较多样本；后两轮缩减为 150 和 50 次采样，用于低成本精炼。该分配的设计意图是降低早期统计量不足和后期重复采样的风险，其效果通过后续四轮采样分配对比进行检验。

### 3.4 main2 等价后处理加速

`code/main2_compare.py` 在相同随机种子和采样次数下比较 `official answer.py`、向量化方案和 Numba 方案。向量化方案缓存同一批随机样本，以批量矩阵运算计算 Ising

---


**Algorithm 2** 四轮协同量子采样

---

**Require:** 权重池  $W$ ，采样次数安排  $[400, 400, 150, 50]$ ，总预算  $B = 100000$

- 1: 用最远点采样从  $W$  中选择 100 个分散权重，作为第一轮活跃方向。
  - 2: 初始化热启动种子库为空。
  - 3: **for**  $r = 1, \dots, 4$  **do**
  - 4:   设置  $c_r = \min\{0.15 + 0.26(r - 1), 0.95\}$ ；该参数从第二轮开始实际生效。
  - 5:   **for** 每个活跃权重  $\lambda_j$  **do**
  - 6:     构造  $P = 4$  热启动 QAOA 线路。
  - 7:     采样  $s_r$  条量子比特串。
  - 8:   **end for**
  - 9:   **if**  $r < 4$  **then**
  - 10:     用五个原始目标评价本轮新样本。
  - 11:     提取跨权重非支配前沿，并按 HV 贡献、极端点、距离和每个权重的种子数量上限筛选。
  - 12:     将选中种子及其来源权重用于下一轮热启动。
  - 13:   **end if**
  - 14: **end for**
  - 15: **return** 严格返回 100000 条量子线路生成的自旋串。
- 

能量；每个数据块先局部压缩非支配点，再延迟合并全局前沿，减少 Python 小循环和重复支配比较。正式向量化路径使用 NumPy、标准库线程和赛题已有的 pygmo，不增加 Numba/JIT 依赖。Numba 方案使用即时编译进一步加速非支配判断的内层热路径，但云端评测环境不能使用该库，因此只在本地作为加速潜力测试。



**图 1** main2 向量化后处理流程

图 1 展示了 main2 的向量化后处理路径。在本次 large10 固定配置下，只有当 hv、完整归一化前沿数组、前沿 HV 和 nd\_count 均与基准一致，且返回前沿本身通过非支配性检查时，才将该次加速记为有效。向量化流程不增加即时编译依赖，Numba 结果仅用于说明热路径的进一步优化空间。

## 四、实验结果与分析

### 4.1 实验设置

小规模 public10 包含 10 个  $4 \times 5$ 、五目标、20 比特实例；所有候选方案每例返回 100000 条量子样本。large10 包含 10 个  $40 \times 50$  实例，main2 统一使用 shots=200000、chunk\_size=4096 和 seed=101。所有本地总分均来自 public10 与对应 large10 运行，不代表 hidden/all 数据集表现。

### 4.2 三类 main1 路线对比

表 1 三类 main1 路线的本地 public10 对比

| 方案      | score_k5          | main2 加分 | 本地总分              | 完整耗时/s        |
|---------|-------------------|----------|-------------------|---------------|
| 强单轮混合深度 | <b>230.016421</b> | 7.472922 | 237.489343        | <b>639.40</b> |
| 简单多轮拓展  | 223.877869        | 7.836676 | 231.714545        | 1449.80       |
| 四轮协同    | 229.920256        | 8.094337 | <b>238.014593</b> | 987.41        |

表 1 汇总三类 main1 路线的本地 public10 结果。将强单轮改为三轮固定标量反馈后，score\_k5 相对强单轮下降 6.138552；在当前 public10 与实现设置下，该完整三轮配置没有带来 HV 增益。四轮协同方案恢复到接近强单轮的 main1 质量，但本地 score\_k5 仍略低于强单轮，完整耗时也更长。因此，在当前本地记录中，强单轮的 main1 质量最高且总体耗时最短；四轮协同则展示了将前沿反馈、热启动与预算分配联合使用的一种可行配置。由于 main2 加分包含独立计时波动，本文判断 main1 路线时以 score\_k5 为主。

强单轮使用多权重和混合深度配置，并在 public10 上取得最高 score\_k5。简单三轮配置低于强单轮；完整四轮配置接近强单轮。现有实验尚未分别隔离各组件的独立贡献，因此本文只报告完整配置之间的比较。

### 4.3 协同轮次与采样次数分配消融

表 2 给出协同方案的轮次与采样次数分配消融。图 2 仅绘制基础轮次序列 1, 2, 3, 4, 5, 6, 避免把特殊四轮采样分配 4f 当作独立轮数连接；4f 与基础四轮配置的差异在表中单独比较。图 3 则作为原始 answer 的独立轮次对照。两图折线表示 public10 的 score\_k5，柱状表示完整运行耗时（秒）。



表 2 Pareto 协同方案的轮次与采样次数分配

| 配置                  | 每权重采样次数                        | score_k5          | main2 加分 | 总分                | 耗时/s    |
|---------------------|--------------------------------|-------------------|----------|-------------------|---------|
| coord_1round        | [1000]                         | 195.563747        | 8.048260 | 203.612007        | 227.71  |
| coord_2round        | [800, 200]                     | 219.058470        | 8.028937 | 227.087407        | 593.05  |
| coord_3round        | [600, 200, 200]                | 225.759503        | 8.041676 | 233.801179        | 787.07  |
| coord_4round        | [400, 200, 200, 200]           | 227.981622        | 8.029948 | 236.011569        | 998.10  |
| coord_4round_2 (4f) | [400, 400, 150, 50]            | <b>229.920256</b> | 8.094337 | <b>238.014593</b> | 987.41  |
| coord_5round        | [300, 200, 200, 150, 150]      | 225.500097        | 8.074428 | 233.574525        | 1188.79 |
| coord_6round        | [250, 150, 150, 150, 150, 150] | 224.855101        | 7.865146 | 232.720247        | 1439.08 |




图 2 协同方案轮次扫描

从一轮到基础四轮配置，`score_k5` 由 195.563747 提高到 227.981622。将四轮采样次数从 [400, 200, 200, 200] 调整为 [400, 400, 150, 50] 后，`score_k5` 提高 1.938634。五轮和六轮配置分别回落到 225.500097 和 224.855101。原始 `answer` 的独立扫描中，五轮取得最高的 `score_k5`=150.653053，六轮回落到 144.379745。由于轮数和采样次数分配同时变化，这里只比较所测试的完整配置，不将差异归因于单一因素。

#### 4.4 与 public10 精确上界的距离

`results/classical_compute_results.json` 对每个公开实例枚举全部  $2^{20} = 1,048,576$  个自旋配置，仅用于分析。其平均精确 HV 为 0.598481003864；结合 `base-line` HV 差值计算，对应可获得的最高 `score_k5`=233.062384，耗时 3356.88 s。该枚举不进入任何提交方案，也不用于生成量子求解器输出。




图 3 原始 answer 轮次扫描

表 3 主方案与 public10 全枚举可获分数增益的距离

| 方案           | score_k5   | 距最高分数    | 可获增益达成率 |
|--------------|------------|----------|---------|
| public10 全枚举 | 233.062384 | 0        | 100%    |
| 强单轮混合深度      | 230.016421 | 3.045963 | 98.693% |
| 四轮协同         | 229.920256 | 3.142128 | 98.652% |

表 3 中的达成率定义为方案 `score_k5` 与全枚举最高 `score_k5` 之比，衡量的是相对 baseline 可获得分数增益的完成比例，而不是绝对 HV 比例。两种主方案在 public10 上均获得了该可获增益的 98.6% 以上，但不能据此推断 hidden set 上具有相同差距。

#### 4.5 main2 large10 结果

表 4 main2 在 large10 上的速度与输出一致性

| 路径                  | 平均耗时/s          | 平均速度提升          | 分数加成            | 输出一致性          |
|---------------------|-----------------|-----------------|-----------------|----------------|
| answer (评分基准)       | 17.804750       | 0               | 0               | official main2 |
| vectorized_pipeline | 5.092364        | 0.714107        | 7.141069        | 10/10 valid    |
| numba_refinement    | <b>4.259303</b> | <b>0.760369</b> | <b>7.603685</b> | 10/10 valid    |

表 4 汇总了 large10 上的运行时间。official `answer.py` 与评分 `baseline.py` 的 `main2` 使用相同求解逻辑，表中采用评分基准批次的平均耗时 17.804750 s。向量化后处理流程的逐 case 平均速度提升为 0.714107，对应 7.141069 分加成；Numba 在本地将平

均时间进一步减少 0.833061 s，说明非支配判断仍有继续压缩空间，但不作为正式云端依赖。

#### 4.6 本地结果与证据边界

本地 public10 中，强单轮混合深度方案的 `score_k5=230.016421`，高于四轮协同方案的 229.920256，且完整耗时 639.40 s，短于四轮协同的 987.41 s。因此本文将强单轮作为本地主方案，将四轮协同作为 Pareto 前沿反馈的对照实现。本地总分还包含独立的 `main2` 计时结果，因此 `main1` 路线比较以 `score_k5` 为主。

### 五、总结与展望

1. **强单轮是当前本地主方案。**它取得最高本地 `score_k5`，且完整耗时最短。
2. **多轮配置用于比较反馈方式。**简单三轮低于强单轮，四轮协同接近强单轮；各组件的独立贡献仍需进一步消融。
3. **`main2` 在固定配置下实现加速。**向量化流程在 `large10`、固定 `seed` 和采样次数下通过 10/10 输出一致性检查，并降低平均运行时间。
4. **后续工作。**后续应减少权重选择中的实例特化规则，以提高未知数据上的稳健性；用更低成本的近似 HV 贡献或增量前沿结构压缩轮间反馈时间；并在不增加采样次数的前提下，自适应判断何时停止反馈，避免进入收益递减区间。

### 参考文献

- [1] FARHI E, GOLDSTONE J, GUTMANN S. A quantum approximate optimization algorithm[A]. 2014.
- [2] MindSpore Quantum. 量子近似优化算法[EB/OL]. 2026. [https://www.mindspore.cn/mindquantum/docs/zh-CN/r0.12/case\\_library/quantum\\_approximate\\_optimization\\_algorithm.html](https://www.mindspore.cn/mindquantum/docs/zh-CN/r0.12/case_library/quantum_approximate_optimization_algorithm.html).
- [3] ZITZLER E, THIELE L. Multiobjective evolutionary algorithms: A comparative case study and the strength pareto approach[J/OL]. IEEE Transactions on Evolutionary Computation, 1999, 3(4): 257-271. DOI: 10.1109/4235.797969.
- [4] FONSECA C M, PAQUETE L, LÓPEZ-IBÁÑEZ M. An improved dimension-sweep algorithm for the hypervolume indicator[C/OL]//2006 IEEE Congress on Evolutionary Computation. IEEE, 2006: 1157-1163. DOI: 10.1109/CEC.2006.1688440.

- [5] KOTIL A, PELOFSKE E, RIEDMÜLLER S, et al. Quantum approximate multi-objective optimization[J/OL]. Nature Computational Science, 2025. DOI: 10.1038/s43588-025-00873-y.
- [6] EGGER D J, MAREČEK J, WOERNER S. Warm-starting quantum optimization[J/OL]. Quantum, 2021, 5: 479. DOI: 10.22331/q-2021-06-17-479.